UNIVERSIDAD MAYOR DE SAN ANDRÉS

FACULTAD DE CIENCIAS PURAS Y NATURALES

CARRERA DE INFORMÁTICA



MÉTODO SIMPLEX

Fundamentos teóricos, aspectos computacionales y aplicaciones

Materia: Métodos Numéricos II - DAT 252

Docente: M.Sc. Carlos Mullisaca Choque

Grupo: 5

Integrantes:

Choque Copa Vidal

Gutierrez Bautista Patricia Maylen

Tema: Programación Lineal

La Paz, Bolivia
Octubre de 2026

ÍNDICE

1. INTRODUCCIÓN..... 2

1.1. Antecedentes del método (George Dantzig, 1947)..... 2

1.2. Objetivos..... 2

2. MARCO TEÓRICO..... 3

2.1. Programación lineal..... 3

2.1.1. Modelo general y supuestos..... 3

2.1.2. Forma estándar y variables de holgura, exceso y artificiales..... 4

2.3. El algoritmo Simplex..... 5

2.3.1. Criterio de optimalidad (costos reducidos)..... 5

2.3.2. Variable de entrada y salida..... 6

2.3.3. Pivoteo y tabla simplex..... 6

2.4. Casos especiales..... 7

2.4.1. Degeneración y ciclado (regla de Bland)..... 7

2.4.2. Problema no acotado e infactible..... 7

2.5. Soluciones iniciales: método de la M grande y de las dos fases..... 7

2.6. Dualidad y análisis de sensibilidad..... 8

3. ASPECTOS COMPUTACIONALES Y APLICACIONES..... 9

3.1. Pseudocódigo del algoritmo..... 9

3.2. Complejidad y estabilidad numérica..... 10

3.3. Aplicaciones en Ciencia de Datos: Regresión LAD..... 10

4. IMPLEMENTACIÓN Y EJERCICIOS..... 11

4.1. Ejercicio 1: maximización (método gráfico y tabla simplex)..... 11

4.2. Ejercicio 2: Estrategia de neumáticos..... 13

4.3. Ejercicio 3: Industria..... 14

5. CONCLUSIONES..... 16

6. REFERENCIAS..... 16

MÉTODO SIMPLEX

1. INTRODUCCIÓN

1.1. Antecedentes del método (George Dantzig, 1947)

Muchos problemas reales consisten en decidir cómo repartir recursos limitados, como dinero, tiempo, materiales o personal, para lograr el mejor resultado posible. Cuando lo que se quiere lograr y las limitaciones se pueden escribir con relaciones lineales, hablamos de **programación lineal (PL)**. Esta técnica es de las más usadas en optimización porque permite representar muchas situaciones distintas con un esquema sencillo y, además, los problemas resultantes son relativamente fáciles de resolver (Sallan et al., 2015).

El método Simplex fue creado por el matemático estadounidense George B. Dantzig. Su trabajo en la Fuerza Aérea de los Estados Unidos lo llevó a enfrentar problemas de planificación muy grandes. Hacia julio de 1947 ya había formulado el problema de la PL y, a finales de ese verano, había desarrollado el método para resolverlo (INFORMS, 2005; O'Connor & Robertson, s. f.).

El nombre también tiene su historia. En esa época, "programación" era un término militar que se refería a planes y calendarios de entrenamiento, abastecimiento o despliegue de tropas, y no a escribir código. El nombre "programación lineal" lo propuso T. J. Koopmans en 1948, durante una visita de Dantzig a la corporación RAND (O'Connor & Robertson, s. f.).

La importancia del Simplex ha perdurado por décadas. El IEEE lo incluyó entre los diez algoritmos más importantes del siglo XX (INFORMS, 2005), y hoy sigue siendo la base para resolver la mayoría de los problemas lineales de forma eficiente (Sallan et al., 2015). La obra de referencia del propio Dantzig, *Linear Programming and Extensions*, publicada por RAND en 1963 y reúne desde la teoría básica hasta la dualidad y las variantes del método (Dantzig, 1963).

1.2. Objetivos

Objetivo general

Explicar el fundamento teórico y el funcionamiento del método Simplex para resolver problemas de programación lineal, con énfasis en su implementación computacional.

Objetivos específicos

- Describir el modelo de programación lineal y su forma estándar.
- Explicar la interpretación geométrica del problema y por qué el óptimo se busca en los vértices de la región factible.
- Detallar el procedimiento del algoritmo Simplex: criterio de optimalidad, variable de entrada y de salida, y pivoteo.
- Identificar los casos especiales (degeneración, problema no acotado e infactible) y los métodos para obtener una solución inicial.
- Analizar los aspectos computacionales del método como el pseudocódigo, complejidad y estabilidad numérica y sus aplicaciones en ciencia de datos.

2. MARCO TEÓRICO

2.1. Programación lineal

La programación lineal (PL) busca la mejor decisión, de máxima ganancia o mínimo costo, cuando hay recursos limitados y todas las relaciones son lineales (Sallan et al., 2015).

2.1.1. Modelo general y supuestos

Un modelo de PL tiene cuatro partes: las variables de decisión x_j, la función objetivo, las restricciones y la no negatividad (Sallan et al., 2015):

$$Max\ (o\ Min)\ z\ =\ c_1 x_1\ +\ c_2 x_2\ +\ \cdots\ +\ c_n x_n\ =\ \sum_{j=1}^{n} c_j x_j$$

$$\text{Sujeto a: } \sum_{j=1}^{n} a_{ij} x_j \{\leq.\ \ =,\ \ \geq\}\ b_i\ (i\ =\ 1,\ldots,m),\ x_j\ \geq\ 0$$

En forma matricial:

$$max\, z\ =\ c^T x\quad s.a.\ \ Ax\ \leq\ b,\ x\ \geq\ 0$$

donde c son los coeficientes de costo o ganancia, A es la matriz de restricciones ($m\ \times\ n$) y b es el vector de recursos disponibles.

Para que un problema se pueda modelar con PL se deben cumplir cuatro **supuestos**:

- **Proporcionalidad:** el aporte de cada variable es proporcional a su valor (si x_j se duplica, su efecto también).

- **Aditividad:** el efecto total es la suma de los efectos individuales, sin interacciones entre variables.
- **Divisibilidad:** las variables pueden tomar valores fraccionarios.
- **Certeza:** todos los coeficientes (a_{ij}, b_i, c_j) son conocidos y constantes.

2.1.2. Forma estándar y variables de holgura, exceso y artificiales

El método Simplex trabaja con la **forma estándar**: todas las restricciones son igualdades, las variables son no negativas y $b \geq 0$ (Sallan et al., 2015):

$max\, c^T x \quad s.a. \quad Ax = b,\ x \geq 0$

Para llegar a ella, un problema de minimizar z se convierte en maximizar $-z$, una restricción con $b_i < 0$ se multiplica por -1, y una variable libre se escribe como $x_j = x_j^+ - x_j^-$ con ambas no negativas. Las desigualdades se convierten en igualdades con variables nuevas:

Restricción	**Variable que se agrega**	**Resultado**
$\sum a_{ij}x_j \leq b_i$	Holgura $s_i \geq 0$ (se suma)	$\sum a_{ij}x_j + s_i = b_i$
$\sum a_{ij}x_j \geq b_i$	Exceso $e_i \geq 0$ (se resta)	$\sum a_{ij}x_j - e_i = b_i$
Tipo $\geq$ o $=$	Artificial $a_i \geq 0$ (se suma)	para iniciar el método (2.5)

La holgura es el recurso que sobra y el exceso, lo que se pasa del mínimo. Ambas tienen coeficiente 0 en z. Las artificiales no tienen significado real: solo sirven para tener una solución inicial.

2.2. Fundamentos matemáticos y geometría

La **región factible** es el conjunto de puntos que cumplen todas las restricciones: $F = \{x: Ax = b, x \geq 0\}$. Un conjunto es **convexo** si el segmento entre dos de sus puntos queda dentro de él. Como cada restricción lineal define un semiespacio convexo y la intersección de convexos es convexa, F siempre es convexa; si además está acotada, se llama politopo. Un vértice (punto extremo) es una "esquina" de F: un punto que no se puede escribir como combinación convexa de otros dos puntos distintos de F.

El **teorema fundamental de la PL** dice que si el problema tiene solución óptima, al menos un vértice de F es óptimo (Ahmed, s. f.; Dantzig, 1963). La idea es que todo punto de F es una combinación convexa de vértices, $x = \sum \lambda_k v_k$, y como z es lineal, $z(x) = \sum \lambda_k z(v_k) \leq \max_k z(v_k)$. Por eso basta buscar entre los vértices, que son una cantidad finita, y no entre infinitos puntos.

Para operar con vértices se usan matrices. En la forma estándar, A $(m \times n)$ se parte en $A = [BN]$, donde la base B $(m \times m)$ es invertible. Poniendo las variables no básicas en cero se obtiene la solución básica:

$$x_B = B^{-1}b, x_N = 0$$

Si además $x_B \geq 0$ es una solución básica factible (SBF). Hay como máximo $\binom{n}{m}$ soluciones básicas. Un resultado clave es que **vértice = punto extremo = SBF** (Ahmed, s. f.): lo que se ve en el dibujo como una esquina es, en el álgebra, una SBF.

2.3. El algoritmo Simplex

La idea es partir de un vértice (una SBF), revisar si moverse a un vértice vecino mejora z y, si es así, moverse. Cuando ningún vecino mejora, se llegó al óptimo (Dantzig, 1963; Patriksson, 2004). Cada movimiento intercambia una variable: una no básica entra a la base y una básica sale.

2.3.1. Criterio de optimalidad (costos reducidos)

Escribiendo z solo con las variables no básicas:

$$z = c_B^T B^{-1} b - \sum_{j \in N} (z_j - c_j) x_j, \qquad donde\ z_j = c_B^T B^{-1} a_j$$

La cantidad $z_j - c_j$ es el costo reducido y mide cómo cambia z al aumentar x_j (Patriksson, 2004). En un problema de maximización: si $z_j - c_j \geq 0$ para todas las no básicas, la solución es óptima. Si algún $z_j - c_j < 0$, aumentar esa variable mejora z.

2.3.2. Variable de entrada y salida

Entra la variable con el costo reducido más negativo, la que más mejora z por unidad (regla de Dantzig): $q = \arg\min_j \{z_j - c_j\}$.

Sale la que primero se vuelve cero al aumentar x_q. Con $d = B^{-1}a_q$, se aplica la razón mínima (Bilkent University, s. f.):

$$\theta^* = \min_{i:d_i>0} \left\{ \frac{(B^{-1}b)_i}{d_i} \right\}$$

La fila r donde se alcanza el mínimo es la variable que sale.

2.3.3. Pivoteo y tabla simplex

Los cálculos se ordenan en una tabla simplex:

Base	$x_1 \cdots x_n$	**Solución**
x_B	$B^{-1}A$	$B^{-1}b$
z	$z_j - c_j$	$c_B^T B^{-1} b$

Una vez elegidos la columna q (entra) y la fila r (sale), el elemento a_{rq} donde se cruzan es el **pivote**. Se hace una operación de **pivoteo**, que es eliminación de Gauss-Jordan:

$$fila_r \leftarrow \frac{fila_r}{a_{rq}}, fila_i \leftarrow fila_i - a_{iq} \cdot fila_r (i \neq r)$$

La fila de z también se transforma de esta manera. Después del pivoteo, la columna de x_q queda como un vector unitario y x_q pasa a ser variable básica.

2.4. Casos especiales

2.4.1. Degeneración y ciclado (regla de Bland)

Una solución es degenerada cuando alguna variable básica vale cero, lo que se nota por un empate en la razón mínima. En esa iteración z no mejora (Bilkent University, s. f.). El riesgo es el ciclado: volver a una base ya visitada y repetir indefinidamente. Es raro en la práctica, pero posible. La regla de Bland lo evita: entre las variables candidatas, siempre se elige la de menor índice, tanto para entrar como para salir en caso de empate. Con ella el algoritmo termina en un número finito de pasos.

2.4.2. Problema no acotado e infactible

Es no acotado si z puede crecer sin límite. Se detecta cuando en la columna de la variable que entra todos los $d_i \leq 0$: x_q crece sin tope y $z \to \infty$. Suele indicar que falta una restricción en el modelo.

Es infactible si ninguna solución cumple todas las restricciones (F = 0). Se descubre en la fase I del método (punto 2.5) cuando las variables artificiales no se pueden eliminar (Patriksson, 2004).

2.5. Soluciones iniciales: método de la M grande y de las dos fases

El Simplex necesita una SBF para empezar. Si todas las restricciones son $\leq$ con $b \geq 0$, las variables de holgura forman la base inicial y se parte del origen. Si hay restricciones $\geq$ o $=$, no hay una base evidente, y se agregan variables artificiales a_i que luego deben llegar a cero (Bilkent University, s. f.).

Método de la M grande. Se penaliza cada artificial en la función objetivo con un número M muy grande:

$$\max\ z = c^T x - M \sum_i a_i$$

Así, el algoritmo tiende a sacar las artificiales de la base. Si al terminar alguna sigue positiva, el problema es infactible.

Método de las dos fases.

- *Fase I:* se minimiza la suma de las artificiales, $\min\ w = \sum a_i$, sujeto a $Ax + a = b$. Si $w^* = 0$, existe una SBF y se pasa a la fase II. Si $w^* > 0$, el problema es infactible (Patriksson, 2004).
- *Fase II:* se descartan las artificiales y se resuelve el problema original partiendo de la base encontrada.

La diferencia práctica es que la M grande es más simple de plantear, pero un M demasiado grande puede causar errores numéricos en la computadora. Por eso las dos fases suelen preferirse en la implementación.

2.6. Dualidad y análisis de sensibilidad

Todo problema de PL (primal) tiene asociado otro problema, el dual, que mira lo mismo desde el lado de los recursos:

$Primal$: $\max\ c^T x, Ax \leq b, x \geq 0 Dual$: $\min\ b^T y, A^T y \geq c, y \geq 0$

Cada restricción del primal da una variable del dual, y cada variable del primal da una restricción del dual. Tres teoremas los conectan:

- Dualidad débil: para cualquier par de soluciones factibles, $c^T x \leq b^T y$. Cada solución del dual da una cota para el primal.
- Dualidad fuerte: si ambos tienen solución óptima, los valores óptimos son iguales: $c^T x^* = b^T y^*$.
- Holgura complementaria: en el óptimo, $y_i^*(b_i - a_i x^*) = 0$. Si a un recurso le sobra, su variable dual vale cero.

Precios sombra. El valor óptimo de la variable dual y_i^* indica cuánto mejora z por cada unidad adicional del recurso i. Se obtiene directamente de la tabla final del Simplex, $y^* = c_B^T B^{-1}$, y permite estimar:

$$\Delta z \approx y_i^* \Delta b_i$$

Esto vale solo dentro de un rango de cambio de b_i. El análisis de sensibilidad estudia justamente cuánto pueden cambiar los coeficientes c_j y los recursos b_i sin que cambie la solución óptima, lo que ayuda a tomar decisiones cuando los datos no son exactos.

3. ASPECTOS COMPUTACIONALES Y APLICACIONES

3.1. Pseudocódigo del algoritmo

El siguiente pseudocódigo resume el método Simplex para un problema de maximización. Es la base para su implementación en un lenguaje de programación (Dantzig, 1963; Patriksson, 2004). Usa una tolerancia **tol**, un número muy pequeño cercano a cero, en lugar de comparar con cero exacto.

Pseudocódigo:

```
SIMPLEX(A, b, c, tol)

    Entrada: A (m×n), b, c en forma estándar
    Salida:  solución óptima x*, valor z*, o un mensaje de estado

    1. Si hay restricciones ≥ o =, aplicar la fase I para obtener
    una base inicial B. Si resulta infactible → RETORNAR
    "INFACTIBLE".

    2. REPETIR:
        a. Calcular x_B = B⁻¹·b  y los costos reducidos  z_j − c_j
    de las no básicas.
        b. Si todos los (z_j − c_j) ≥ −tol → RETORNAR x*, z* =
    c_Bᵀ·x_B   (óptimo).
       c. Elegir la variable que entra, q: la de menor z_j − c_j
           (con regla de Bland: la de menor índice con z_j − c_j <
    −tol).
       d. Calcular d = B⁻¹·a_q.
          Si todos los d_i ≤ tol → RETORNAR "NO ACOTADO".
       e. Calcular la razón mínima θ* = min{ (B⁻¹b)_i / d_i : d_i >
    tol }
          y la fila r donde ocurre: esa variable sale.
       f. Pivotear sobre (r, q) y actualizar la base B.
```

3.2. Complejidad y estabilidad numérica

Costo por iteración. En la implementación con tabla, cada pivoteo actualiza una tabla de tamaño aproximado $m \times n$, así que cada iteración cuesta del orden de $O(mn)$ operaciones.

Número de iteraciones. En el peor caso, el Simplex es exponencial. En 1972, Klee y Minty construyeron problemas de PL con n variables en los que el método, con la regla del mayor coeficiente, necesita $2^n - 1$ pivoteos. Aun así, en la práctica funciona muy bien: Vanderbei (2013) señala que el peor caso es del orden de $n^2 2^n$ operaciones, mientras que en promedio es del orden de n^3. Por eso sigue siendo tan usado, pese a que existen algoritmos de tiempo polinomial, como los métodos de puntos interiores (University of Washington, 2010). Estos últimos, como el de Karmarkar, resultan más eficientes en algunos tipos de problemas (Sallan et al., 2015).

Estabilidad numérica. En la computadora los números se guardan con precisión limitada (punto flotante), por lo que aparecen errores de redondeo. Un valor que debería ser exactamente cero puede quedar como un número diminuto, y esto puede causar decisiones equivocadas en la prueba de optimalidad o en la razón mínima. Para evitarlo, las implementaciones usan una tolerancia cercana a la precisión de la máquina para decidir si un número es "cero" (Ryan, 2021). Además, los pivotes muy pequeños amplifican los errores, y por eso las implementaciones robustas emplean estrategias como el escalado de los datos, la perturbación y técnicas contra la degeneración (Smidla, 2021).

3.3. Aplicaciones en Ciencia de Datos: Regresión LAD

En regresión lineal, el método de mínimos cuadrados minimiza la suma de los errores al cuadrado, y los valores atípicos (*outliers*) lo afectan mucho. La alternativa es la regresión por mínimas desviaciones absolutas (LAD o norma L1), que minimiza la suma de los errores en valor absoluto:

$$\min_{\beta} \sum_{i=1}^{N} \left| y_i - x_i^T \beta \right|$$

Aunque la función con valor absoluto no es lineal, este problema se puede reescribir como un problema de programación lineal (Vanderbei, 2014). Para ello, cada error se separa en una parte positiva y una negativa, $y_i - x_i^T \beta = u_i - v_i$ con $u_i, v_i \geq 0$, y se minimiza su suma:

$$\min \sum_{i=1}^{N} (u_i + v_i) s.a. x_i^T \beta + u_i - v_i = y_i, u_i, v_i \geq 0$$

Los coeficientes β pueden ser negativos, por lo que se escriben como $\beta = \beta^+ - \beta^-$, con ambas partes no negativas. Al minimizar, en el óptimo solo una de las dos variables u_i, v_i es distinta de cero, de modo que su suma es justamente el valor absoluto del error.

La ventaja es que la regresión LAD es mucho menos sensible a los valores atípicos que los mínimos cuadrados, lo que la hace útil en datos reales con mediciones erróneas. Como es un programa lineal, se puede resolver con el método Simplex o con herramientas como **scipy.optimize.linprog** de Python.

4. IMPLEMENTACIÓN Y EJERCICIOS

4.1. Ejercicio 1: maximización (método gráfico y tabla simplex)

Maximizar $z = 4x_1 + 3x_2$

Sujeto a:

- $2x_1 + x_2 \leq 10$ (R_1)
- $x_1 + x_2 \leq 8$ (R_2)
- $x_1 \leq 4$ (R_3)
- $x_1, x_2 \geq 0$

Forma estándar. Se agregan holguras $s_1, s_2, s_3 \geq 0$:

- $2x_1 + x_2 + s_1 = 10$
- $x_1 + x_2 + s_2 = 8$
- $x_1 + s_3 = 4$

Iteración 0 (inicial):

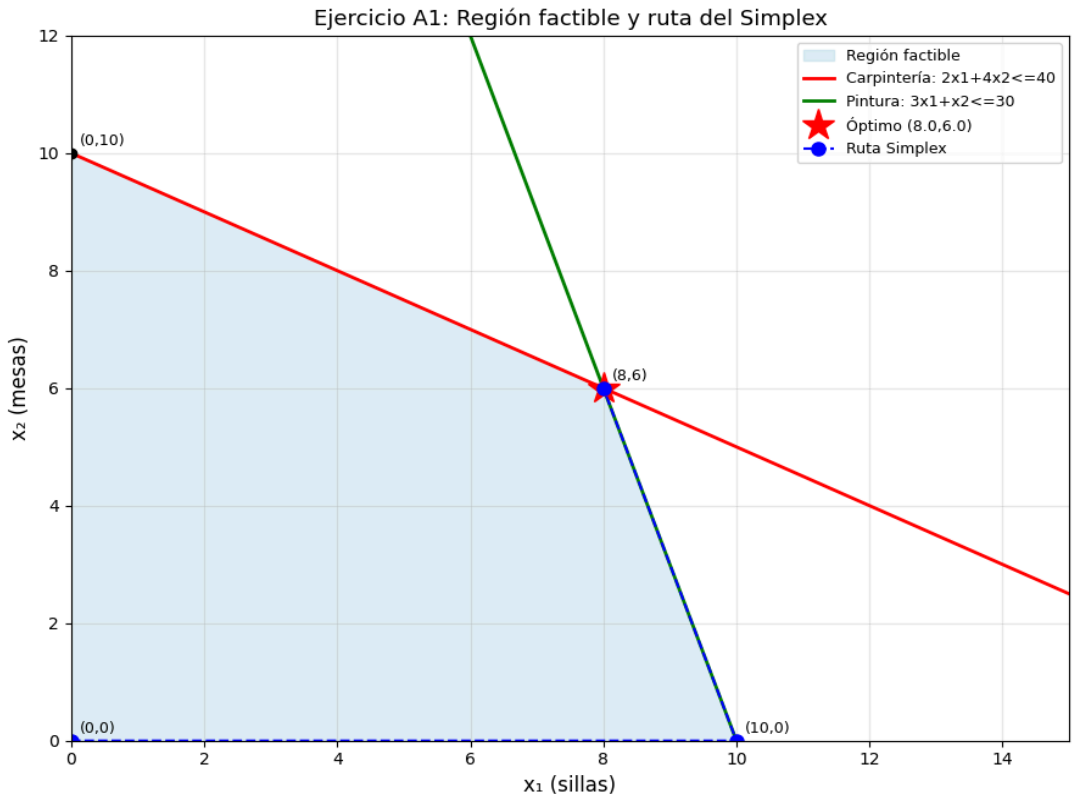
Base	x1	x2	s1	s2	sol
s1	2.00	4.00	1.00	0.00	40.00
s2	3.00	1.00	0.00	1.00	30.00
z	-30.00	-50.00	0.00	0.00	0.00

Iteración 1

Base	x1	x2	s1	s2	sol
s1	2.00	4.00	1.00	0.00	40.00
s2	3.00	1.00	0.00	1.00	30.00
z	-30.00	-50.00	0.00	0.00	0.00

Iteración 2

Base	x1	x2	s1	s2	sol
s1	0.00	1.00	0.30	0.20	6.00
s2	1.00	0.00	-0.10	0.40	8.00
z	0.00	0.00	12.00	2	540



4.2. Ejercicio 2: Estrategia de neumáticos

PROBLEMA:

Un equipo de F1 planifica dos compuestos: blandos (x1) y duros (x2).

Rendimiento: 8 puntos por blando, 5 por duro.

Restricciones:

3x1 + 2x2 <= 18 (caucho)

x1 + 2x2 <= 12 (tiempo en boxes)

x1 + x2 <= 8 (desgaste de frenos)

OBJETIVO: maximizar el rendimiento total.

Se agregan holguras s1, s2, s3 >= 0:

3*x1 + 2*x2 + s1 = 18

1*x1 + 2*x2 + s2 = 12

1*x1 + 1*x2 + s3 = 8

z - 8*x1 - 5*x2 = 0

Iteración 0:

Base	x1	x2	s1	s2	s3	sol
s1	3.00	2.00	1.00	0.00	0.00	18.00
s2	1.00	2.00	0.000	1.00	0.00	12.00
s3	1.00	1.00	0.00	0.00	1.00	8.00
z	-8.00	-5.00	0.00	0.00	0.00	0.00

Iteración 1:

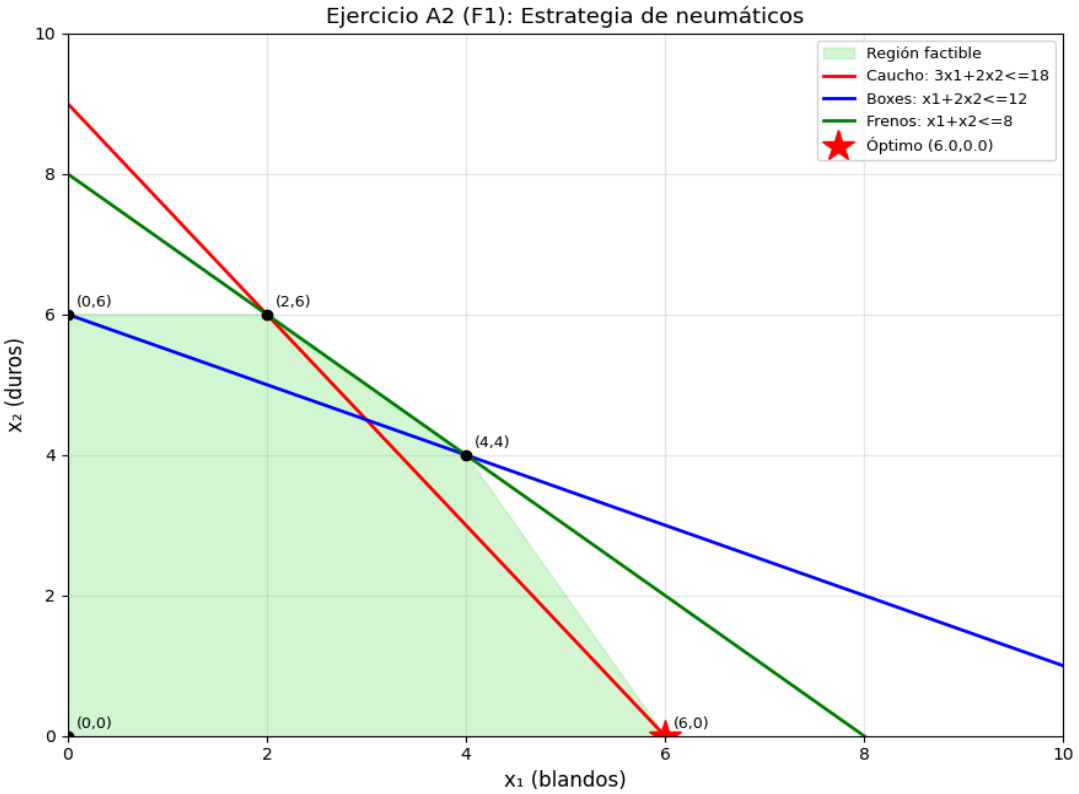
Base	x1	x2	s1	s2	s3	sol
s1	1.00	0.67	0.33	0.00	0.00	6.00
s2	0.00	1.33	-0.33	1.00	0.00	6.00
z	0.00	0.33	-0.33	0.00	1.00	2.00
z	0.00	0.33	2.67	0.00	0.00	48.00

Solución Óptima:

x1 = 6.00 juegos blandos

x2 = 0.00 juegos duros

z = 48.00 puntos



4.3. Ejercicio 3: Industria

PROBLEMA: *Mezcla con restricciones (>=) y (=)*

La planta química produce aleación A (x1) y B (x2).

Ganancia: $400/ton de A, $300/ton de B.

Restricciones:

x1 + x2 >= 10 (mínimo total)

x1 = 4 (compromiso exacto)

x1 + x2 <= 15 (capacidad máxima)

OBJETIVO: maximizar la ganancia.

Restricción >= : se agrega exceso e1 y artificial a1:

x1 + x2 - e1 + a1 = 10

Restricción = : se agrega artificial a2:

x1 + a2 = 4

Restricción <= : se agrega holgura s3:

x1 + x2 + s3 = 15

Tabla Inicial Fase I:

Base	x1	x2	s1	s2	s3		sol
s1	1	1	-1	1	0	0	10
s2	1	0	0	0	1	0	4
z	1	1	0	0	0	1	15
w	2	1	-1	0	0	0	14

Iteración 1: Entra x1, sale a2 (razón 4/1=4)

Iteración 2: Entra x2, sale a1 (razón 6/1=6)

Fase I: termina con w = 0 -> hay solución factible

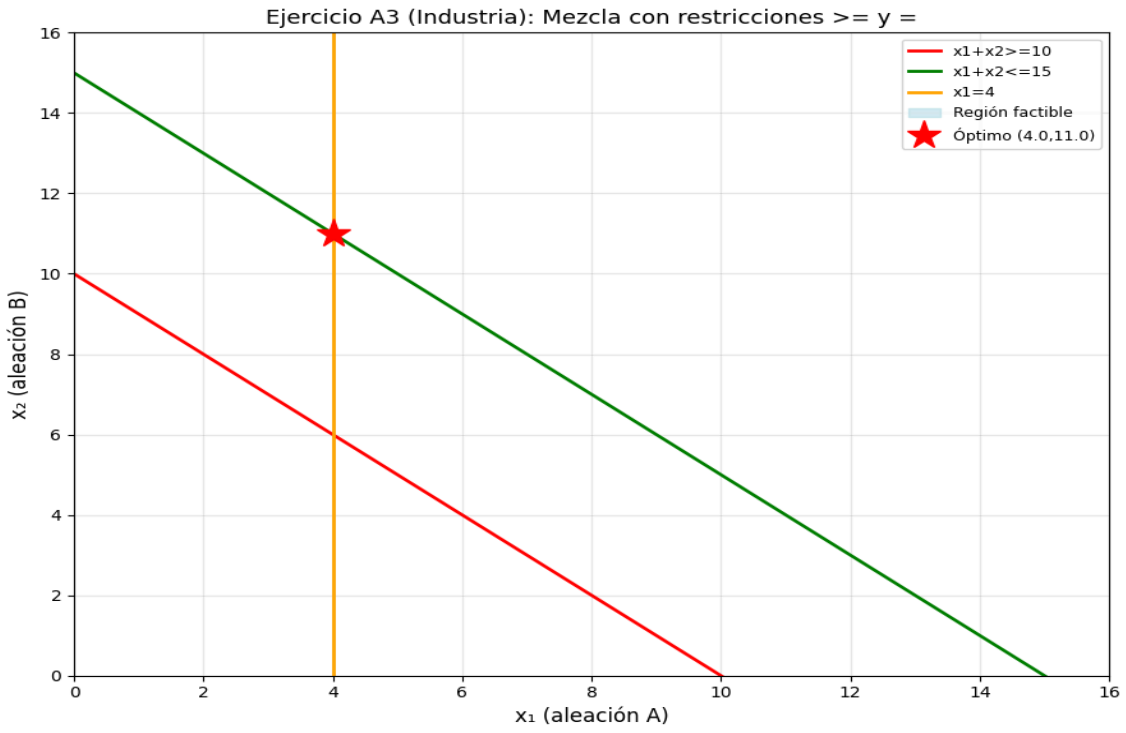
Base inicial para Fase II: {x2, x1, s3}

Fase II: x1 = 4

x2 = 6 + e1

s3 = 5 - e1

z = 400(4) + 300(6 + e1) = 3400 + 300*e1



5. CONCLUSIONES

El método Simplex, creado por George B. Dantzig en 1947, sigue siendo una de las herramientas más importantes de la optimización moderna. Su fortaleza radica en el teorema fundamental de la programación lineal: si existe solución óptima, al menos un vértice de la región factible lo es. Esto reduce un problema con infinitas soluciones a una búsqueda finita sobre soluciones básicas factibles, lo que explica su eficiencia y vigencia por más de siete décadas.

El algoritmo funciona mediante iteraciones que intercambian variables básicas y no básicas, usando los costos reducidos ($z_j - c_j$) para decidir qué variable entra, y la razón mínima para decidir cuál sale. El pivoteo, basado en Gauss-Jordan, actualiza la tabla hasta alcanzar el óptimo. Sin embargo, el método debe manejar casos especiales como degeneración, ciclado, no acotación e infactibilidad. Para esto existen la regla de Bland, que garantiza terminación finita, y los métodos de la M grande y de las dos fases, siendo este último preferido por su mayor estabilidad numérica.

Aunque el Simplex es exponencial en el peor caso, en la práctica se comporta como un algoritmo de orden $O(n^3)$ en promedio, lo que lo mantiene competitivo frente a métodos de puntos interiores. La dualidad y el análisis de sensibilidad amplían su utilidad, permitiendo interpretar los precios sombra como estimaciones del impacto de cambios en los recursos. Además, sus aplicaciones en ciencia de datos, como la regresión LAD, demuestran su versatilidad más allá de la investigación de operaciones.

6. REFERENCIAS

Ahmed, S. (s. f.). *Linear programming: Geometry, algebra and the simplex method* [Notas de clase, ISyE 3133]. Georgia Institute of Technology. simplex

Bilkent University. (s. f.). *Lecture 5: Simplex for min problems, degeneracy, Big M and two-phase methods* [Notas de clase, IE 400]. IE400_Set4_Simplex_Method

Chalmers University of Technology. (s. f.). *Lecture 9: Linear programming duality and sensitivity* [Notas de clase, TMA947]. lecture9.pdf

Dantzig, G. B. (1963). *Linear programming and extensions*. RAND Corporation. Programación lineal y extensiones | RAND

INFORMS. (2005, 1 de agosto). The life and times of the father of linear programming. *INFORMS News*. LA VIDA Y ÉPOCA DEL PADRE DE LA PROGRAMACIÓN LINEAL | ORMS hoy

O'Connor, J. J., & Robertson, E. F. (s. f.). *George Bernard Dantzig*. MacTutor History of Mathematics Archive, University of St Andrews. George Dantzig (1914 - 2005) - Biografía - MacTutor Historia de las Matemáticas

Patriksson, M. (2004). *Lecture 9: The simplex method* [Notas de clase, TMA947]. Chalmers University of Technology. lecture9.dvi

Sallan, J. M., Lordan, O., & Fernandez, V. (2015). *Modeling and solving linear programming with R*. OmniaScience. Modeling and solving linear programming with R

University of Washington. (2010). *Math 409, Lecture 4: Running times of algorithms (continued)* [Notas de clase]. lecture4.pdf

Vanderbei, R. J. (2014). *L1 regularization via the parametric simplex method* [Presentación, MOPTA 2014]. L1_reg.pdf